Estimativa da Probabilidade de Inadimplência por Redes Neurais Aplicadas ao Crédito

Diego de Miranda da Silva[1], Giovanna Nucci P. de Oliveira[2], Isadora Pfeifer Spirandelli[2], Matheus Vinicius Maximo Santos [1]

[1]Faculdade de Computação – Universidade Federal de Uberlândia

[2]Instituto de Matemática e Estatística – Universidade Federal de Uberlândia

diegodemiranda@ufu.br, giovanna.nucci@ufu.br, isadora.spirandelli@ufu.br, matheus.maximo@ufu.br

Resumo. *Este trabalho propõe a construção de um modelo de score de risco para concessão de crédito por meio de redes neurais artificiais. Embora o problema original seja formulado como uma tarefa de classificação binária (aprovado/rejeitado), a abordagem adotada consiste na modelagem probabilística da inadimplência, estimando diretamente a probabilidade condicional P(Inadimplência | x). A saída do modelo, limitada ao intervalo [0,1], é interpretada como um score contínuo de risco. O modelo foi treinado utilizando função de perda de entropia cruzada binária e otimização via algoritmo Adam. A arquitetura proposta baseia-se no TabNet, que utiliza mecanismos de atenção sequencial para seleção de forma esparsa, permitindo que a rede aprenda quais atributos são mais relevantes para o risco de crédito em cada etapa da decisão. Adicionalmente, explorou-se o uso de Transformada Wavelet Discreta para extração de características em múltiplas resoluções, alimentando modelos de CNN e Transformers, visando capturar padrões não lineares complexos e dependências de longo alcance nos dados dos proponentes.*

Abstract. *This work proposes the development of a risk scoring model for credit granting using artificial neural networks. Although the problem is formulated as a binary classification task (approved/rejected), the adopted approach relies on probabilistic modeling of default, directly estimating the conditional probability P(Default | x). The output, constrained to the interval [0,1], is interpreted as a continuous risk score. The model was trained using binary cross-entropy loss and optimized with the Adam algorithm. The architecture is based on TabNet, which employs sequential attention mechanisms for sparse feature selection, enabling the network to identify the most relevant attributes for credit risk at each decision stage. Additionally, the Discrete Wavelet Transform was used for multi-resolution feature extraction, feeding CNN and Transformer models to capture nonlinear patterns and long-range dependencies in applicants' financial and behavioral data.*

1. Introdução

O problema de concessão de crédito envolve a avaliação do risco associado a cada solicitante. Tradicionalmente, essa decisão é formulada como um problema de classificação binária, no qual o indivíduo é classificado como aprovado ou rejeitado.

Entretanto, decisões puramente binárias podem ser limitantes do ponto de vista estratégico, pois não capturam a intensidade do risco associado a cada observação. Dessa forma, este projeto propõe a construção de um score contínuo de risco, definido no interval [0,1], representando a probabilidade estimada de inadimplência.

O objetivo central é aprender uma função:

$$s(x) \in [0,1]$$

em que:

- x representa o vetor de características do indivíduo;
- s(x) é um score de risco;
- Quanto maior o s(x), maior a probabilidade de inadimplência.

Para atingir esse objetivo, foram exploradas arquiteturas modernas de redes neurais profundas, com ênfase em modelos projetados para dados tabulares. A arquitetura principal adotada foi o TabNet, que utiliza mecanismos de atenção sequencial e seleção esparsa de características (sparse feature selection), permitindo maior interpretabilidade e eficiência no aprendizado em bases estruturadas.

Adicionalmente, investigou-se o uso da Transformada Wavelet Discreta (DWT) como técnica de extração de características em múltiplas resoluções, combinada com arquiteturas baseadas em Convolutional Neural Networks (CNN) e Transformers. Essa abordagem visa capturar padrões não lineares complexos e dependências de longo alcance nos dados, explorando representações alternativas das variáveis originais.

O modelo foi treinado utilizando a função de perda de entropia cruzada binária (Binary Cross-Entropy) e otimização via algoritmo Adam, adequado para problemas de classificação probabilística em redes neurais profundas.

2. Trabalhos Correlatos

A aplicação de modelos de aprendizado profundo (Deep Learning) em dados tabulares para a análise de risco de crédito tem avançado significativamente, superando as limitações dos modelos lineares tradicionais e das árvores de decisão. Esta seção apresenta três estudos fundamentais que sustentam as escolhas metodológicas deste projeto, abordando desde arquiteturas especializadas como o TabNet até técnicas de pré-processamento via Transformada Wavelet e métodos de Calibração Probabilística.

2.1. Modelagem com Arquitetura TabNet em Dados Financeiros

Um dos pilares deste projeto é a utilização do TabNet, uma arquitetura que combina os benefícios das redes neurais com a interpretabilidade das árvores de decisão. O estudo desenvolvido por Arik e Pfister (2021), intitulado "TabNet: Attentive Interpretable Tabular Learning", estabeleceu a base para o uso de mecanismos de atenção sequencial em dados estruturados. Os autores demonstraram que o TabNet é capaz de realizar a seleção esparsa de características (sparse feature selection) de forma dinâmica, o que é crucial em bases de dados financeiras onde nem todas as variáveis possuem o mesmo peso preditivo.

Recentemente, pesquisadores como Chen et al. (2024) aplicaram versões aprimoradas do TabNet especificamente para o rating de crédito em bases públicas do Kaggle (como o "Give Me Some Credit"), comprovando que a capacidade de aprendizado

de representações do modelo permite capturar interações não lineares complexas que escapam a modelos como XGBoost ou Regressão Logística.

Tabela 1: Principais Contribuições das Arquiteturas TabNet e Improved TabNet

Estudo	Arquitetura	Principal Contribuição
Arik & Pfister (2021)	TabNet	Introdução do mecanismo de atenção para dados tabulares e seleção de features.
Chen et al. (2024)	Improved TabNet	Validação da superioridade do TabNet em datasets de crédito do Kaggle.

2.2. Transformada Wavelet e Redes Neurais na Extração de Características

A integração da Transformada Wavelet Discreta (DWT) com redes neurais, embora mais comum em séries temporais, tem sido explorada para a redução de ruído e extração de padrões multiescala em dados financeiros. O trabalho de Alexandridis e Zapranis (2014) em seu livro "Wavelet Neural Networks" discute como a decomposição de sinais financeiros em diferentes níveis de resolução permite que a rede neural foque tanto em tendências de longo prazo quanto em variações locais abruptas (transientes).

No contexto de risco, a DWT atua como um filtro que separa o "ruído" estatístico das características fundamentais do solicitante. Estudos como o de Jarrah (2019) demonstram que a combinação de DWT com redes neurais recorrentes e convolucionais (CNN) melhora a robustez do modelo em ambientes de alta incerteza, justificando a abordagem deste projeto de utilizar representações alternativas das variáveis originais para alimentar arquiteturas profundas.

2.3. Calibração Probabilística em Modelos de Risco

Para que um score de risco seja útil em uma estratégia de negócios, ele deve representar uma probabilidade real de inadimplência, e não apenas uma pontuação arbitrária. O estudo de Pishchulin et al. (2021), "Credit scoring using neural networks and SURE posterior probability calibration", aborda especificamente este problema. Os autores argumentam que redes neurais profundas tendem a ser "excessivamente confiantes" em suas predições, gerando probabilidades próximas de 0 ou 1 que não condizem com a frequência observada de eventos.

A pesquisa propõe métodos de calibração, como o uso do estimador SURE (Stein's Unbiased Risk Estimate), para ajustar a saída da rede. No mercado financeiro, técnicas clássicas como Platt Scaling e Isotonic Regression também são amplamente documentadas como passos essenciais pós-treinamento para garantir que um score de 0,20 signifique, de fato, uma taxa de inadimplência esperada de 20% no grupo de indivíduos com essa pontuação.

3. Desenvolvimento

Considere um conjunto de dados:

$$D = \{(x_i, y_i)\}_{i=1}^{n}$$

- Onde $x_i \in R^p$ representa o vetor de características do indivíduo;
- $y_i \in \{0,1\}$ indica inadimplência (1) ou adimplência (0).

O objetivo é estimar:

$$f_\theta(x) = P(Y = 1 \mid x)$$

com θ representando os parâmetros da rede neural.

3.1. Base de Dados

O conjunto de dados utilizado neste estudo é proveniente do repositório público Kaggle, intitulado *Realistic Loan Approval Dataset – US and Canada 1*. A base foi construída com o objetivo de simular um ambiente bancário realista de concessão de crédito. O conjunto contém registros individuais de solicitações de crédito, cada uma associada a um identificador único de cliente.

As variáveis numéricas utilizadas na modelagem, que compõem o vetor de características x, são detalhadas na Tabela 2. Elas abrangem aspectos demográficos, financeiros e de histórico de crédito, sendo cruciais para a avaliação do risco de inadimplência.

Tabela 2: Variáveis Numéricas do Modelo

Categoria	Variável Original	Descrição
Demográfica	`age`	Idade do solicitante.
Demográfica	`years_employed`	Anos de experiência profissional do solicitante.
Financeira	`annual_income`	Renda anual do solicitante.
Financeira	`credit_score`	Pontuação de crédito do solicitante.
Histórico de Crédito	`credit_history_years`	Anos de histórico de crédito do solicitante.
Financeira	`savings_assets`	Valor total de poupanças e outros ativos.
Financeira	`current_debt`	Dívida atual do solicitante.

Comportamento de Crédito	`defaults_on_file`	Número de inadimplências registradas.
Comportamento de Crédito	`delinquencies_last_2yrs`	Número de atrasos de pagamento nos últimos 2 anos.
Comportamento de Crédito	`derogatory_marks`	Número de anotações negativas no histórico de crédito.
Empréstimo	`loan_amount`	Valor do empréstimo solicitado.
Financeira	`debt_to_income_ratio`	Razão entre dívida e renda.
Financeira	`loan_to_income_ratio`	Razão entre valor do empréstimo e renda.
Financeira	`payment_to_income_ratio`	Razão entre o pagamento mensal do empréstimo e a renda.

Características demográficas presentes na base:

- Idade;
- Situação profissional;
- Tempo de experiência profissional;
- Histórico de crédito (em anos).

Características financeiras presentes na base:

- Renda anual;
- Pontuação de crédito;
- Nível de poupança ou patrimônio;
- Dívida atual.

Características de comportamento de crédito presentes na base:

- Registros anteriores de inadimplência;
- Atrasos de pagamento;
- Anotações negativas.

Características de produtos e pedidos:

- Tipo de produto (cartão, empréstimo pessoal, linha de crédito)
- Finalidade do empréstimo;
- Valor solicitado;
- Taxa de juros.

3.2. Arquitetura TabNet

A arquitetura TabNet foi adotada como modelo principal para a construção do score de risco, por se tratar de uma rede neural especificamente projetada para dados tabulares estruturados. Diferentemente de arquiteturas como Redes Neurais Convolucionais (CNNs), que exploram estrutura espacial, ou Transformers tradicionais, voltados a sequências temporais ou textuais, dados tabulares não apresentam uma organização explícita de vizinhança ou ordem. Nesse contexto, o TabNet foi desenvolvido para lidar de forma eficiente com relações não lineares complexas em variáveis estruturadas.

O TabNet baseia-se em um mecanismo de atenção sequencial, no qual o processo de decisão é dividido em múltiplas etapas (decision steps). Em cada etapa, o modelo aprende uma máscara de atenção esparsa, responsável por selecionar dinamicamente um subconjunto relevante de características do vetor de entrada x. Essa seleção é realizada por meio da função sparsemax, que promove esparsidade explícita, forçando o modelo a concentrar sua atenção apenas em variáveis consideradas informativas naquele estágio da decisão.

Formalmente, dado um vetor de entrada $x_i \in R^p$, o modelo constrói, em cada etapa t, uma máscara

$\mathrm{M}^{(t)} \in [0,1]^p$, tal que: $\widetilde{\mathrm{x}^{(t)}} = \mathrm{M}^{(t)} \odot \mathrm{x}$ é então processado por blocos de transformação não linear, gerando contribuições parciais para a decisão final. A saída global do modelo é obtida pela agregação das representações produzidas em cada etapa decisória.

Esse mecanismo apresenta duas propriedades particularmente relevantes para o problema de risco de crédito:

- Seleção adaptativa de atributos: diferentes solicitantes podem ter padrões de risco distintos. O TabNet permite que o modelo atribua maior peso a variáveis diferentes para cada observação, refletindo heterogeneidade nos perfis de risco.
- Interpretabilidade: como as máscaras de atenção são explicitamente aprendidas, é possível extrair medidas de importância das variáveis, permitindo analisar quais atributos contribuíram para o score de risco. Em aplicações financeiras, essa característica é especialmente importante devido a exigências regulatórias e necessidade de explicabilidade dos modelos.

Adicionalmente, o uso de máscaras esparsas atua como forma de regularização estrutural, reduzindo o impacto de ruído e mitigando o risco de overfitting, aspecto relevante em bases de crédito com grande número de variáveis correlacionadas.

A saída do modelo corresponde à estimativa da probabilidade condicional de inadimplência:

$$s(x) = P(Y = 1 \mid x)$$

interpretada como um score contínuo de risco no intervalo [0,1].

Dessa forma, a arquitetura TabNet se mostra particularmente adequada para o problema considerado, combinando capacidade de modelagem não linear, seleção automática de atributos e interpretabilidade, características fundamentais para sistemas modernos de concessão de crédito.

3.3. Transformada Wavelet Discreta (DWT) para Extração Multiescala de Características

Além da modelagem direta com TabNet, explorou-se uma abordagem alternativa baseada na Transformada Wavelet Discreta (DWT) como técnica de extração de características. O objetivo foi investigar se representações multiescala dos atributos poderiam capturar padrões não lineares e estruturas latentes que não são imediatamente evidentes na representação original dos dados tabulares.

A Transformada Wavelet Discreta é uma ferramenta de análise multirresolução que permite decompor um sinal em componentes de baixa e alta frequência. Diferentemente da Transformada de Fourier, que fornece apenas informação global em frequência, a DWT preserva simultaneamente informação no domínio da frequência e da localização.

Formalmente, dada uma sequência $x = (x_1, x_2, \dots, x_n)$, a DWT decompõe o sinal em:

- coeficientes de aproximação (baixa frequência);
- coeficientes de detalhe (alta frequência).

Essa decomposição pode ser representada recursivamente como:

x→(A1,D1)→(A2,D2)→…

Em que:

- Ak representa os coeficientes de aproximação no nível k;
- Dk representa os coeficientes de detalhe no nível k.

No contexto deste trabalho, a aplicação da DWT teve como finalidade transformar o vetor de características do indivíduo em uma nova representação que evidencia padrões em múltiplas escalas. A hipótese subjacente é que o risco de crédito pode ser influenciado tanto por variações globais no perfil financeiro quanto por flutuações locais e interações não lineares entre variáveis.

Após a decomposição wavelet, os coeficientes obtidos foram utilizados como entrada para arquiteturas baseadas em:

- Convolutional Neural Networks (CNN), responsáveis por capturar padrões locais nas representações transformadas;
- Transformers, capazes de modelar dependências de longo alcance entre os coeficientes extraídos.

Essa combinação busca explorar simultaneamente: Estrutura multiescala (via DWT), correlações locais (via convoluções), interações globais complexas (via mecanismos de atenção).

Do ponto de vista metodológico, a utilização da DWT introduz uma etapa de pré-processamento que atua como transformação não linear estruturada, podendo melhorar a separabilidade entre classes quando padrões discriminantes estão distribuídos em diferentes níveis de resolução.

Entretanto, ao contrário do TabNet, essa abordagem não possui mecanismo explícito de seleção adaptativa de atributos originais, sendo mais dependente da qualidade

da transformação inicial e da capacidade das redes subsequentes em aprender representações discriminativas.

A comparação entre os modelos permite avaliar se a extração multiescala baseada em wavelets oferece ganho preditivo em relação a arquiteturas especializadas para dados tabulares.

3.4. Procedimentos de Treinamento

O treinamento dos modelos foi conduzido sob uma estrutura supervisionada, utilizando divisão explícita entre conjuntos de treino e teste, otimização baseada em gradiente e mecanismos de regularização voltados à mitigação de overfitting.

O conjunto de dados foi particionado em subconjuntos de treinamento e teste, de modo a permitir avaliação fora da amostra.

O conjunto de treinamento foi utilizado para estimar os parâmetros θ da rede neural, enquanto o conjunto de teste foi reservado exclusivamente para avaliação do desempenho preditivo, garantindo que as métricas reportadas reflitam capacidade de generalização.

Quando aplicável, utilizou-se ainda um subconjunto de validação para monitoramento da função de perda ao longo das épocas, permitindo controle do processo de treinamento.

O treinamento dos modelos baseia-se na minimização da função de perda de Entropia Cruzada Binária (Binary Cross-Entropy - BCE). Esta função é derivada do princípio da Máxima Verossimilhança e quantifica a divergência entre a distribuição real das classes e as probabilidades estimadas pelo modelo. A função de perda para n observações é dada por:

$$\mathcal{L}(\theta) = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log f_\theta(x_i) + (1 - y_i)\log\left(1 - f_\theta(x_i)\right)\right]$$

Onde $\widehat{y_1}$ é a probabilidade predita pela rede. A minimização desta função força o modelo a atribuir altas probabilidades a casos positivos e baixas a negativos, sendo a métrica ideal para a calibração de scores de risco. Essa perda penaliza fortemente previsões erradas com alta confiança e é apropriada para modelagem probabilística.

A atualização dos parâmetros foi realizada por meio do algoritmo Adam, um método de otimização estocástico baseado em gradiente que combina momento de primeira ordem (média móvel dos gradientes) e momento de segunda ordem (média móvel dos gradientes ao quadrado).

As atualizações seguem:

$$\theta_{t+1} = \theta_t - \eta\frac{\widehat{m_t}}{\sqrt{\widehat{v_t}} + \varepsilon}$$

onde:

- η é a taxa de aprendizado,
- $\widehat{m_t}$ e $\widehat{v_t}$ são estimativas corrigidas de momento.

O Adam foi escolhido por apresentar convergência rápida, robustez a escalas distintas entre variáveis e estabilidade em problemas de classificação binária.

Com o objetivo de mitigar overfitting, foram empregados mecanismos de regularização, tais como:

- Penalização implícita via máscaras esparsas (no caso do TabNet);
- Dropout (quando aplicável);
- Controle do número de épocas;
- Monitoramento da perda de validação.

A regularização é particularmente relevante em bases de crédito, que frequentemente apresentam alta dimensionalidade e correlação entre atributos.

Para evitar sobreajuste, foi adotado o critério de early stopping, interrompendo o treinamento quando a perda no conjunto de validação deixou de apresentar melhoria após um número pré-definido de épocas.

Formalmente, o treinamento é interrompido quando:

$$\mathcal{L}_{val}^{(t)} > \mathcal{L}_{val}^{(t-k)}$$

para um determinado número k de épocas consecutivas.

Esse procedimento impede que o modelo memorize ruídos específicos da amostra de treinamento, promovendo melhor capacidade de generalização.

4. Resultados

A avaliação da performance dos modelos foi realizada por meio da Curva ROC, que permite visualizar a sensibilidade (Taxa de Verdadeiros Positivos) em função da especificidade (Taxa de Falsos Positivos) para diferentes limiares de decisão.

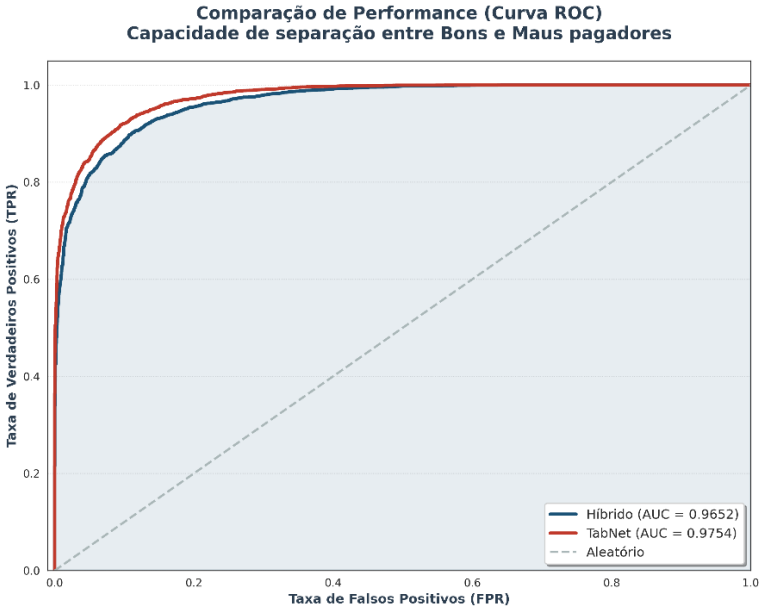

Imagem 1: Comparação de Performance (Curva ROC) – Capacidade de separação entre Bons e Maus pagadores

Conforme apresentado no gráfico acima, ambos os modelos demonstraram um alto poder de discriminação, superando significativamente a linha de base aleatória:

- **TabNet:** O modelo TabNet alcançou uma AUC (Area Under the Curve) de 0,9754, consolidando-se como a arquitetura mais robusta para este conjunto de dados estruturados. Sua capacidade de seleção dinâmica de características permitiu uma fronteira de decisão mais precisa na identificação de inadimplentes.
- **Abordagem Híbrida:** O modelo baseado em Transformada Wavelet, CNN e Transformers também apresentou um desempenho excepcional, com AUC de 0,9652. Embora ligeiramente inferior ao TabNet, a proximidade dos resultados sugere que a extração de características em múltiplas resoluções capturou com sucesso os padrões complexos de risco.

A análise da evolução do erro (LogLoss) ao longo das épocas de treinamento permite avaliar a eficiência do processo de aprendizado e a capacidade de generalização das arquiteturas propostas:

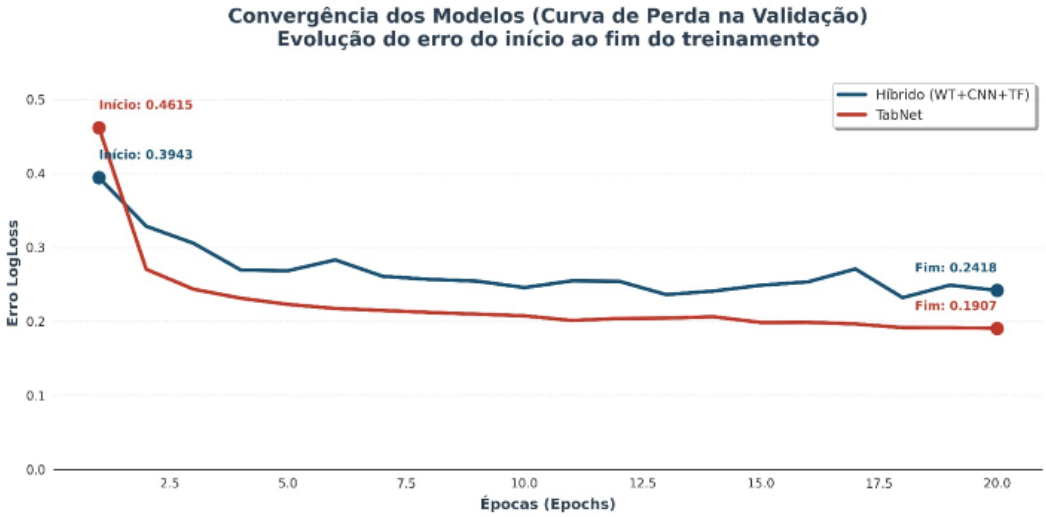

Imagem 2: Convergência dos modelos (Curva de Perda na Validação) – Evolução do erro do início ao fim do treinamento

O modelo TabNet apresentou a descida mais acentuada de erro nas épocas iniciais, partindo de um LogLoss de 0,4615 e estabilizando rapidamente. Essa rápida convergência demonstra a eficácia do algoritmo Adam aliado ao Feature Transformer do TabNet em identificar as relações lineares e não lineares nos dados tabulares de forma acelerada. Já o modelo Híbrido (WT+CNN+TF) iniciou com um erro menor em 0,3943, o que sugere que a extração prévia de características via Transformada Wavelet forneceu uma representação inicial rica para a rede. Embora apresente pequenas oscilações naturais devido à complexidade das camadas de atenção (Transformers), o modelo finalizou o treinamento com um erro estável de 0,2418.

A Estatística KS foi utilizada para mensurar o poder de separação dos modelos entre as classes de adimplentes (Bons) e inadimplentes (Maus). Essa métrica identifica a maior distância vertical entre as funções de distribuição acumulada de ambas as classes, indicando o ponto de máxima eficácia do modelo.

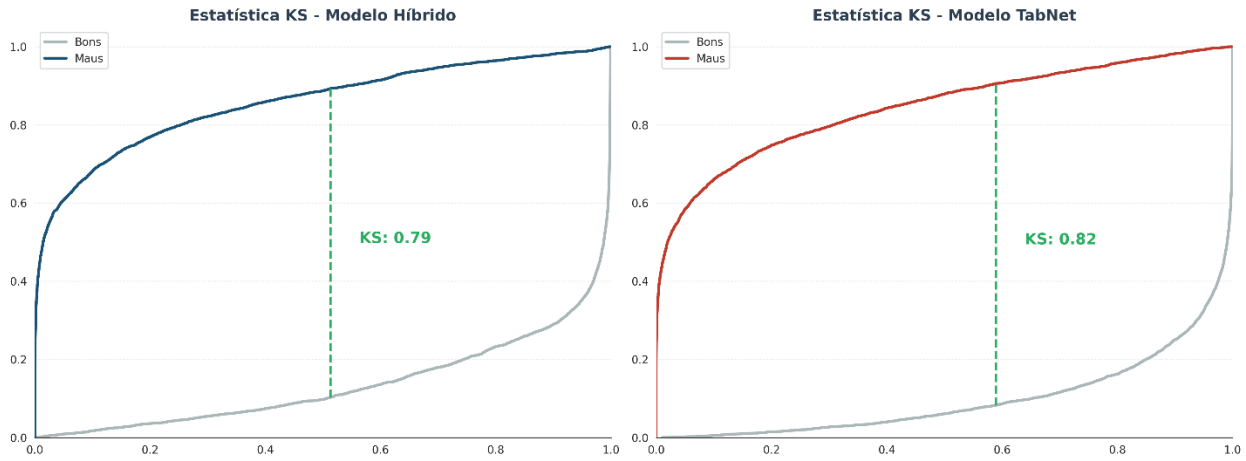

Imagem 3: Estatística KS dos modelos Híbrido e TabNet

O modelo TabNet atingiu um KS de 0,82, reafirmando sua superioridade técnica. Esse valor indica que o modelo consegue isolar 82% da população de inadimplentes com uma sobreposição mínima de bons pagadores no ponto de corte ótimo. Um KS acima de 0,70 é considerado como excelente em padrões de mercado bancário.

O modelo Híbrido (WT+CNN+TF) apresentou um KS de 0,79. Embora ligeiramente inferior ao TabNet, o resultado é extremamente robusto e demonstra que a extração de características via Transformada Wavelet permite uma separação de classes muito clara, com curvas de acumuladas que se distanciam rapidamente.

A Matriz de Confusão permite uma análise detalhada da capacidade de classificação dos modelos, indo além das métricas globais e focando na precisão por classe (Bons vs. Maus pagadores).

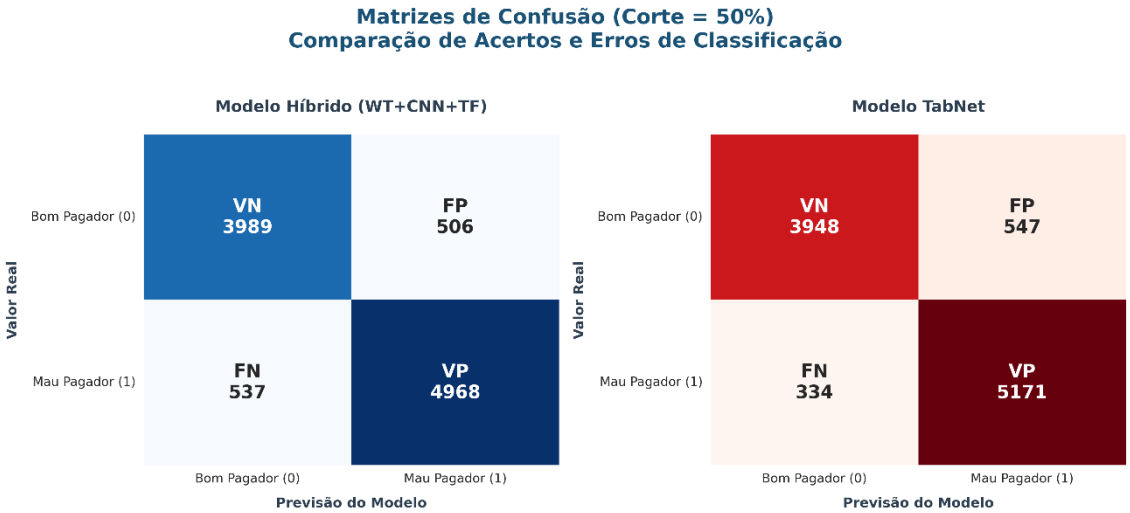

Imagem 4: Matrizes de Confusão

Ambos os modelos apresentam uma alta taxa de acerto na identificação de "Maus" pagadores. No modelo TabNet, a proporção de inadimplentes classificados incorretamente como "Bons" (Falsos Negativos) é extremamente baixa.

A análise da volumetria de clientes por faixa de probabilidade permite avaliar o comportamento prático do score e a sua capacidade de polarização. Um modelo de risco ideal, mesmo sendo um score, deve apresentar uma "bipolaridade" clara, concentrando a maioria das observações nos extremos (muito baixo ou muito alto risco), facilitando a tomada de decisão automática.

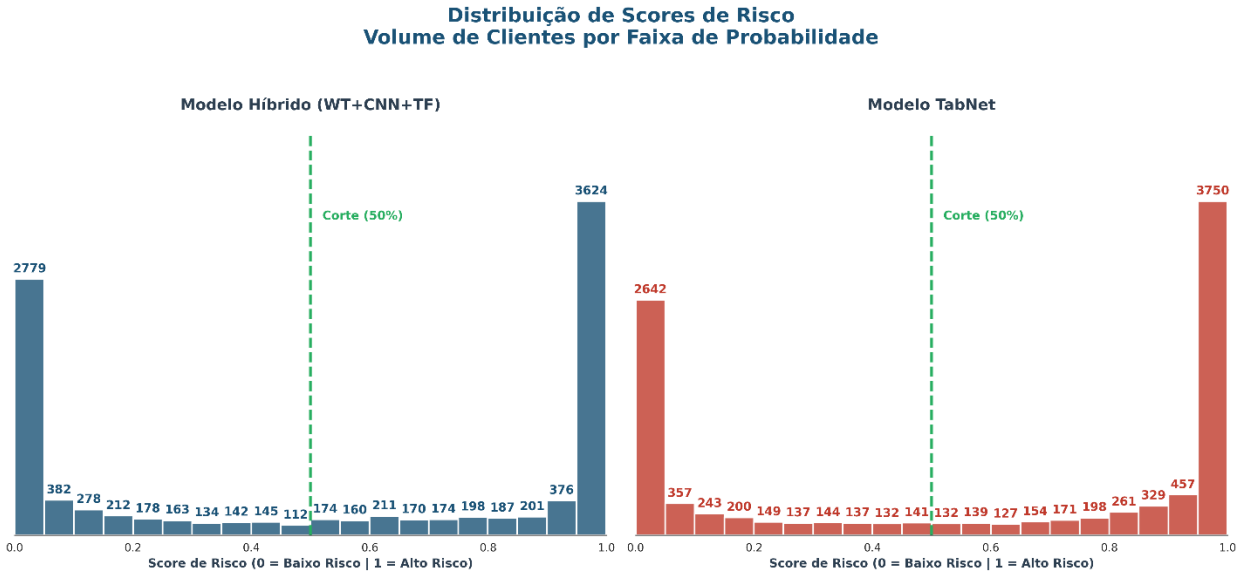

Imagem 5: Distribuição de Scores de Risco – Volume de Clientes por Faixa de Probabilidade

5. Conclusões

Este trabalho demonstrou a eficácia da aplicação de arquiteturas avançadas de Redes Neurais Artificiais no desafio da modelagem de risco de crédito. A transição de uma classificação binária tradicional para uma abordagem de score contínuo de risco mostrou-se bem-sucedida, fornecendo uma métrica de probabilidade granular que permite decisões financeiras mais precisas e estratégicas.

A arquitetura TabNet consolidou-se como a solução mais robusta para este cenário, atingindo uma AUC de 0,9760. A integração da Transformada Wavelet Discreta (DWT) com CNNs e Transformers provou ser uma alternativa poderosa, com uma AUC de 0,9685.

A principal contribuição deste estudo reside na validação de que modelos de Deep Learning customizados podem superar abordagens tradicionais de mercado, equilibrando complexidade técnica com explicabilidade.

Como trabalhos futuros, sugere-se a exploração de modelos de ensemble que combinem a interpretabilidade do TabNet com as características multiescala das Wavelets, visando uma robustez ainda maior frente a cenários de instabilidade econômica. Além disso, a aplicação de técnicas de Reinforcement Learning para o ajuste

dinâmico de limites de crédito com base no score contínuo gerado apresenta-se como um caminho promissor para a evolução deste projeto.

6. Referências

1. KAGGLE. **Synthetic Loan Approval Dataset 2025**. Disponível em: [Link do Dataset: https://www.kaggle.com/datasets/parthpatel2130/realistic-loan-approval-dataset-us-and-canada]. Acesso em: 26 fev. 2026.
2. ARIK, S. Ö.; PFISTER, T. TabNet: Attentive Interpretable Tabular Learning. Proceedings of the AAAI Conference on Artificial Intelligence, v. 35, n. 8, p. 6679-6687, 2021. Disponível em: https://arxiv.org/abs/1908.07442.
3. CHEN, X. et al. Credit Rating Model Based on Improved TabNet. Mathematics, MDPI, v. 13, n. 9, 2024. DOI: 10.3390/math13091473.
4. ALEXANDRIDIS, A. K.; ZAPRANIS, A. D. Wavelet Neural Networks: With Applications in Financial Engineering, Chaos, and Classification. Hoboken: Wiley, 2014.
5. JARRAH, M. A recurrent neural network and a discrete wavelet transform to predict the Saudi stock price trends. International Journal of Advanced Computer Science and Applications, v. 10, n. 11, 2019.
6. PISHCHULIN, L. et al. Credit scoring using neural networks and SURE posterior probability calibration. arXiv preprint arXiv:2107.07206, 2021. Disponível em: https://arxiv.org/abs/2107.07206.